

Observations : à quelle intensité le modèle cesse-t-il de voir ?

Ce document rassemble les mesures faites avec `etalonnage.py` et les explications demandées à l'oral. Les valeurs dépendent de l'objet, de l'éclairage et de la distance : **refaites la mesure devant votre caméra** avec `python3 etalonnage.py` (ou à la main dans `tp_filtres.py`) et complétez le tableau de la section 3.

Modèle : YOLOv4-tiny (COCO, 80 classes), entrée 320 px, seuil de confiance 0,5.

1. Mesures sur deux images de test (640 px de large)

Image A : deux personnes en gros plan (2 objets détectés à l'origine). Image B : scène de rue avec trois personnes (3 objets détectés à l'origine).

Filtre	Plage réglable	Premier objet perdu (A / B)	Plus aucun objet (A / B)
niveaux de gris	0 → 100 %	90 % / jamais	jamais / jamais
flou	1 → 61 px	5 px / 31 px	~35 px / 53 px
contours	seuil 10 → 400	dès 10 / dès 10	dès 10 / dès 10
seuillage	seuil 0 → 255	partout instable	170 / 180
bruit	sigma 0 → 120	sigma 15 / sigma 15	instable au-delà de 30
pixellisation	1 → 64 px	3 px / 5 px	4 px / 7 px
posterisation	0 → 7 bits supprimés	4 bits / 7 bits	jamais / jamais
assombrissement	0 → 100 %	30 % / 85 %	100 % / 100 %
inversion	0 → 100 %	30 % / 30 %	50 % / jamais

Deux précautions de lecture :

- **Un objet « détecté » n'est pas forcément le bon.** Sur une image très floue (35 à 61 px) ou très bruitée, le modèle peut renvoyer une boîte « person » au mauvais endroit : le compteur remonte alors que l'image est illisible. À l'oral, regardez la classe et la position de la boîte, pas seulement le compteur.
- **Le bruit est tiré à chaque image** : le compteur clignote autour du seuil. C'est pour cela que `etalonnage.py` moyenne plusieurs tirages.

2. Pourquoi tel filtre gêne-t-il plus que tel autre ?

Le fil conducteur : **le modèle ne voit pas comme nous**. Il a appris des *statistiques* de pixels sur des photos naturelles (COCO). Tout ce qui garde ces statistiques passe ; tout ce qui

les change le rend aveugle, même quand l'image reste évidente pour un œil humain.

Ce que le modèle supporte très bien

- **Niveaux de gris** : quasiment aucun effet, même à 100 %. La couleur est un indice mineur : ce sont les formes, les contours et les textures qui déclenchent les filtres de convolution. De plus, l'entraînement de YOLO utilise de l'*augmentation de données* (variations de teinte et de saturation), le réseau a donc déjà vu des images presque incolores.
- **Postérisation** : réduire à 16 ou 8 niveaux par canal ne change pas la structure de l'image (les gros aplats restent, les contours restent). Le modèle décroche seulement quand il ne reste que 2 niveaux, c'est-à-dire quand la postérisation devient un seuillage.
- **Assombrissement** jusqu'à 80-90 % : le réseau normalise les pixels dans $[0, 1]$ mais aucune normalisation par image n'est faite, donc les activations baissent. Elles restent pourtant *proportionnelles* : les contrastes relatifs sont conservés jusqu'à ce que la quantification sur 8 bits (des valeurs entières) écrase tout vers 0.

Ce qui le gêne progressivement

- **Flou** : un flou gaussien supprime les hautes fréquences, c'est-à-dire les textures fines et les contours nets. Or les premières couches du réseau sont précisément des détecteurs de bords et de textures. Quand le noyau dépasse la taille des détails distinctifs de l'objet (yeux, logo, bords du téléphone), il ne reste que la silhouette et les scores tombent sous 0,5. Les gros objets proches résistent plus longtemps que les petits, ce qui explique l'écart entre les images A et B. L'œil, lui, reconnaît une silhouette floue sans effort.
- **Pixellisation** : c'est un flou brutal *plus* des faux contours (les bords des gros pixels). À 8 px, une image 640×480 ne contient plus que 80×60 informations ; envoyée au réseau en 320×320, chaque objet fait quelques « gros pixels » seulement. Le modèle perd très vite, alors qu'un humain lit encore la scène à 16 px.

Ce qui le rend aveugle alors que l'image reste lisible

- **Bruit** (le plus surprenant) : à sigma 15-20, le bruit est à peine visible à l'œil, et pourtant le modèle perd des objets. Un bruit indépendant sur chaque pixel est un signal de très haute fréquence : il excite fortement les détecteurs de bords des premières couches, dans toutes les directions et partout dans l'image. L'erreur se propage et s'amplifie de couche en couche. Notre système visuel, lui, moyenne naturellement le bruit (intégration spatiale) et ne le remarque pas. C'est le même mécanisme que les *exemples adverses* : une perturbation invisible qui bascule la décision.
- **Contours (Canny)** : aveugle dès la plus petite intensité. L'image devient binaire : fond noir, traits blancs, plus aucune texture ni dégradé. Les statistiques d'entrée n'ont plus rien à voir avec une photo ; les couches de *batch normalization* ont été calibrées sur des photos naturelles et produisent des activations aberrantes. Pour nous, un dessin au trait d'un visage ou d'une bouteille est immédiatement reconnaissable.

- **Seuillage** : même raison (image binaire), avec en plus une perte d'information réelle : tout ce qui est plus sombre ou plus clair que le seuil fusionne en un aplat. Le compteur remonte parfois vers 20-60 : ce sont souvent de fausses détections sur des taches noires et blanches.
- **Inversion** : à 100 % l'image est parfaitement lisible pour nous (un négatif), mais un ciel noir, une peau bleu-vert et une ombre blanche ne ressemblent à rien de ce que le réseau a appris. Le passage par 50 % (image grise uniforme, contraste nul) est le point le plus destructeur.

Résumé pour l'oral

Le filtre...	...conserve	...détruit	Effet sur le modèle
gris, postérisation	formes, contours, textures	couleur, nuances	quasi nul
assombrissement	contrastes relatifs	amplitude	faible jusqu'à ~85 %
flou, pixellisation	silhouette	détails fins (hautes fréquences)	progressif, dépend de la taille de l'objet
bruit	tout, pour l'œil	rien de visible, mais ajoute des hautes fréquences partout	fort et précoce
contours, seuillage, inversion	lisibilité pour l'œil	les statistiques d'une photo naturelle	aveugle presque immédiatement

L'idée à retenir : **la robustesse du modèle ne suit pas la lisibilité humaine**. Il est robuste aux transformations présentes dans ses données d'entraînement (couleur, luminosité, échelle) et fragile à tout ce qui déplace l'image hors de la distribution des photos naturelles (bruit, binarisation, négatif).

3. Mesures devant la caméra (à compléter en séance)

Objet	Filtre	Intensité où la détection lâche